

Introduction

We will begin with a short tutorial on regression, polynomial features, and regularization based on a very simple, sparse data set that contains a column of X data and associated Y noisy data. The data file is called `X_Y_Sinusoid_Data.csv`.

```
In [10]: import os
data_path = ['data']

# Importing the data
# Also generate approximately 100 equally spaced x data points over the range of 0.0 to 1.0. Using these points, calculate the "ground truth" (the real function) from the equation: y = xsin(2πx)
# Plot the sparse data (X vs y) and the calculated ("real") data.

In [16]: import pandas as pd
import numpy as np

filepath = os.path.join(data_path + ['X_Y_Sinusoid_Data.csv'])
data = pd.read_csv('C:\Users\rsmeu\Desktop\10M\X_Y_Sinusoid_Data.csv')

X_real = np.linspace(0, 1.0, 100)
Y_real = np.sin(2 * np.pi * X_real)

In [19]: data.head()

Out[19]:
   X      Y
0  0.008071  0.066391
1  0.166776  1.027483
2  0.335531  1.245302
3  0.504289  1.004781
4  0.673046  1.264212

In [18]: X_real

Out[18]:
array([0.008071, 0.016142, 0.024213, 0.032284, 0.040355, 0.048426, 0.056497, 0.064568, 0.072639, 0.08071, 0.088781, 0.096852, 0.104923, 0.112994, 0.121065, 0.129136, 0.137207, 0.145278, 0.153349, 0.16142, 0.169491, 0.177562, 0.185633, 0.193704, 0.201775, 0.209846, 0.217917, 0.225988, 0.234059, 0.24213, 0.250201, 0.258272, 0.266343, 0.274414, 0.282485, 0.290556, 0.298627, 0.306698, 0.314769, 0.32284, 0.330911, 0.338982, 0.347053, 0.355124, 0.363195, 0.371266, 0.379337, 0.387408, 0.395479, 0.40355, 0.411621, 0.419692, 0.427763, 0.435834, 0.443905, 0.451976, 0.460047, 0.468118, 0.476189, 0.48426, 0.492331, 0.500402, 0.508473, 0.516544, 0.524615, 0.532686, 0.540757, 0.548828, 0.556899, 0.56497, 0.573041, 0.581112, 0.589183, 0.597254, 0.605325, 0.613396, 0.621467, 0.629538, 0.637609, 0.64568, 0.653751, 0.661822, 0.669893, 0.677964, 0.686035, 0.694106, 0.702177, 0.710248, 0.718319, 0.72639, 0.734461, 0.742532, 0.750603, 0.758674, 0.766745, 0.774816, 0.782887, 0.790958, 0.799029, 0.8071, 0.815171, 0.823242, 0.831313, 0.839384, 0.847455, 0.855526, 0.863597, 0.871668, 0.879739, 0.88781, 0.895881, 0.903952, 0.912023, 0.920094, 0.928165, 0.936236, 0.944307, 0.952378, 0.960449, 0.96852, 0.976591, 0.984662, 0.992733, 1.0.

In [12]: Y_real

array([0.00800000e+00, 6.34235197e-02, 1.26524546e-01, 1.89251244e-01, 2.51978075e-01, 3.12834440e-01, 3.72624250e-01, 4.29704925e-01, 4.85186173e-01, 5.40488178e-01, 5.92967026e-01, 6.42767618e-01, 6.90791015e-01, 7.36571700e-01, 7.79464646e-01, 8.14707020e-01, 8.49724340e-01, 8.81453638e-01, 9.06313958e-01, 9.24147868e-01, 9.39887339e-01, 9.59874128e-01, 9.76854776e-01, 9.89851056e-01, 9.99821422e-01, 1.0.

In [14]: import matplotlib.pyplot as plt
import seaborn as sns
matplotlib inline

In [17]: sns.set_style('white')
sns.set_context('talk')
sns.set_palette('dark')

# Plot of the noisy (sparse)
ax = data.set_index(['Y'])
ax.plot(X_real, Y_real, ls='-', markers='o', label='data')
ax.plot(X_real, Y_real, ls='-', markers='o', label='real function')
ax.legend()
ax.set(xlabel='x data', ylabel='y data')

In [12]:
# Using the PolynomialFeatures class from Scikit-learn's preprocessing library, create 20th order polynomial features.
# Fit the model using linear regression.
# Plot the resulting predicted value compared to the calculated data.

Note that the PolynomialFeatures requires either a dataframe (with one column, not a Series) or a 2D array of dimension (X, 1), where X is the length.

We have to make the polynomial features either data frame with one column or a 2D array of dimension (X, 1), we want to ensure that we have a two-dimensional array, we can't just pass in just one column or a series.

We want to make it in the form of perhaps a data frame, as we see here, or a two-dimensional array. So we import polynomial features, our linear regression.
```

```
In [18]: from sklearn.preprocessing import PolynomialFeatures
from sklearn.linear_model import LinearRegression

# Setup the polynomial features
degree = 20
pf = PolynomialFeatures(degree)
lr = LinearRegression()
# Fit linear regression on that expanded version of X.

# Extract the X and y data from the dataframe
X_data = data[['X']]
y_data = data[['Y']]

# Create the features and fit the model
X_poly = pf.fit_transform(X_data)
y_pred = lr.fit(X_poly, y_data)
y_pred = lr.predict(X_poly)

# Plot the result
plt.plot(X_data, y_data, markers='o', ls='', label='data', alpha=1)
plt.plot(X_data, y_pred, markers='o', ls='', label='real function')
plt.plot(X_data, y_pred, markers='o', ls='', label='predictions w/ polynomial features')
ax = plt.gca()
ax.set(xlabel='x data', ylabel='y data')

In [18]:
# Performing the regression on the data with polynomial features using ridge regression (alpha=0.001) and lasso regression (alpha=0.0001).
# Plot the results as was done in Question 1.
# Also plot the magnitude of the coefficients obtained from these regressions, and compare them to those obtained from linear regression in the previous question. The linear regression coefficients will likely need a separate plot (or their own y-axis) due to their large magnitude.
```

```
In [22]: # Note the sklearn warning about regularization
import warnings
warnings.filterwarnings('ignore', module='sklearn')

from sklearn.linear_model import Ridge, Lasso

# We're going to say lr equal to our ridge object, with an alpha = 0.001.
# We're then going to fit that to our x_poly that we defined before.
# Note that the 20 degree polynomial as well as our y_data.
# The ridge regression model

rr = Ridge(alpha=0.001)
rr = rr.fit(X_poly, y_data)
y_pred_rr = rr.predict(X_poly)

# The lasso regression model
lasso = Lasso(alpha=0.0001)
lasso = lasso.fit(X_poly, y_data)
y_pred_lasso = lasso.predict(X_poly)

# The plot of the predicted values
plt.plot(X_data, y_data, markers='o', ls='', label='data')
plt.plot(X_data, y_pred_rr, markers='o', ls='', label='real function')
plt.plot(X_data, y_pred_lasso, markers='o', ls='', label='ridge regression', alpha=0.5)
plt.plot(X_data, y_pred_lasso, markers='o', ls='', label='lasso regression', alpha=0.5)
ax = plt.gca()
ax.set(xlabel='x data', ylabel='y data')

In [22]:
# Let's look at the absolute value of coefficients for each model
coefficients = pd.DataFrame()
coefficients['linear regression'] = lr.coef_.ravel()
coefficients['ridge regression'] = rr.coef_.ravel()
coefficients['lasso regression'] = lasso.coef_.ravel()
coefficients = coefficients.applymap(abs)
coefficients.describe() # Hope difference in scale between non-regularized vs regularized regression

Out[22]:
linear regression  ridge regression  lasso regression
count            2000000000  2000000000  2000000000
mean            1.777094e+13  2.189897e+13  2.187036e+13
std             6.031941e+13  2.900278e+13  4.706711e+13
min            1.619371e+07  0.000000e+00  0.000000e+00
25%            3.416390e+12  0.407578e+12  0.200331e+12
50%            3.621180e+13  1.017272e+13  0.200331e+12
75%            1.070540e+14  2.883507e+13  1.641353e+13
max            1.655347e+14  12.429635e+13  20.176708e+13
```

```
In [25]: (coefficients>0.0).sum()

In [26]: linear regression 21
ridge regression 20
lasso regression 19
dtype: int64

In [37]: colors = sns.color_palette()

# Setup the dual y-axes
ax1 = plt.gca()
ax2 = ax1.twinx()

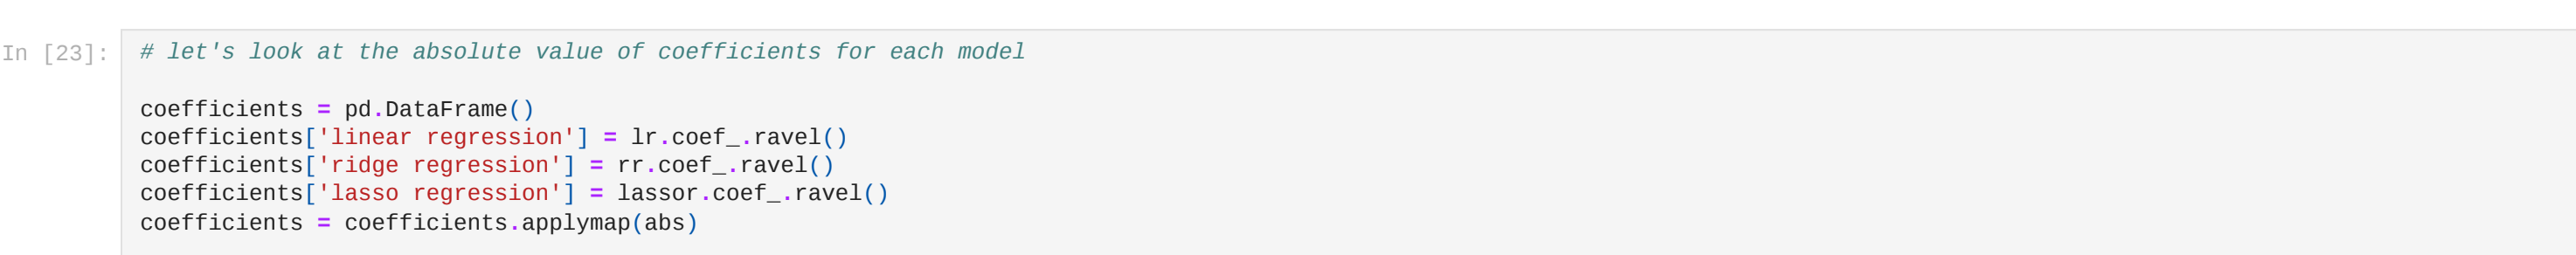
# Plot the linear regression data
ax1.plot(lr.coef_.ravel(), color=colors[0], label='linear regression')

# Plot the regularization data sets
ax2.plot(rr.coef_.ravel(), color=colors[1], label='ridge regression')
ax2.plot(lasso.coef_.ravel(), color=colors[2], label='lasso regression')

# Customize axes scales
ax1.set_xlabel('data', fontsize=14)
ax2.set_ylabel('coefficients', fontsize=14)

# Combine the legends
h1, l1 = ax1.get_legend_handles_labels()
h2, l2 = ax2.get_legend_handles_labels()
ax1.legend(nin=h1+h2, li=l1+l2)

ax1.set(xlabel='coefficients', ylabel='linear regression')
ax2.set(ylabel='ridge and lasso regression')
ax1.set_xticks(range(len(lr.coef_)))
```



We will be working with the `data` set which is based on housing prices in Ames, Iowa. There are an extensive number of features to begin:

- Import the data with Pandas, remove any null values, and one-hot encode categorical. Either Scikit-learn's feature encoders or Pandas `get_dummies` method can be used.
- Split the data into train and test sets.
- Log transform skewed features.
- Scaling can be attempted, although it can be interesting to see how well regularization works without scaling features.

```
In [39]: filepath = os.path.join(data_path + ['Ames_Housing_Sales.csv'])
data = pd.read_csv('C:\Users\rsmeu\Desktop\10M\Ames_Housing_Sales.csv', sep=',')

In [40]: len(data.columns)

Out[40]: 80

In [41]: data.head()

Out[41]:
   Id      SalePrice  2SsnPorch  Alley  BedroomAbvGr  BldgType  BsmntExposure  BsmntFinSF1  BsmntFinSF2  ...  ScreenPorch  Street  TotHmsAbvGr  TotHmsBsmntF  Utilities  WoodDeckSF  YearBuilt  YearRemodAdd
0  8650    86500      0.0  None  None  BedroomAbvGr  BldgType  BsmntExposure  BsmntFinSF1  BsmntFinSF2  ...  ScreenPorch  Street  TotHmsAbvGr  TotHmsBsmntF  Utilities  WoodDeckSF  YearBuilt  YearRemodAdd
1  12620    9200      0.0  None  3  1Fam  TA  Gd  978.0  0.0  ...  0.0  Pave  6  3820.0  AP/Hb  28.0  1976  1976
2  9200    8650      0.0  None  3  1Fam  TA  Mn  486.0  0.0  ...  0.0  Pave  6  3820.0  AP/Hb  0.0  2001  2001
3  9160    7560      0.0  None  3  1Fam  Gd  No  216.0  0.0  ...  0.0  Pave  7  7560.0  AP/Hb  0.0  1915  1970
4  14150   10510      0.0  None  4  1Fam  TA  Av  615.0  0.0  ...  0.0  Pave  9  1145.0  AP/Hb  182.0  2000  2000  1970

Create a list of categorical data and one-hot encode. Pandas one-hot encoder (get_dummies) works well with data that is defined as a categorical.
```

```
In [46]: # Do the one-hot encoding
data = pd.get_dummies(data, columns=one_hot_encode_cols)

In [46]: data = pd.get_dummies(data, drop_first=True)
data.columns

Out[46]:
Index(['1stFlrSF', '2ndFlrSF', '3SsnPorch', 'BedroomAbvGr', 'BsmntFinSF1', 'BsmntFinSF2', 'BsmntFinSF3', 'BsmntFinSF4', 'BsmntFinSF5', 'BsmntFinSF6', 'BsmntFinSF7', 'BsmntFinSF8', 'BsmntFinSF9', 'BsmntFinSF10', 'BsmntFinSF11', 'BsmntFinSF12', 'BsmntFinSF13', 'BsmntFinSF14', 'BsmntFinSF15', 'BsmntFinSF16', 'BsmntFinSF17', 'BsmntFinSF18', 'BsmntFinSF19', 'BsmntFinSF20', 'BsmntFinSF21', 'BsmntFinSF22', 'BsmntFinSF23', 'BsmntFinSF24', 'BsmntFinSF25', 'BsmntFinSF26', 'BsmntFinSF27', 'BsmntFinSF28', 'BsmntFinSF29', 'BsmntFinSF30', 'BsmntFinSF31', 'BsmntFinSF32', 'BsmntFinSF33', 'BsmntFinSF34', 'BsmntFinSF35', 'BsmntFinSF36', 'BsmntFinSF37', 'BsmntFinSF38', 'BsmntFinSF39', 'BsmntFinSF40', 'BsmntFinSF41', 'BsmntFinSF42', 'BsmntFinSF43', 'BsmntFinSF44', 'BsmntFinSF45', 'BsmntFinSF46', 'BsmntFinSF47', 'BsmntFinSF48', 'BsmntFinSF49', 'BsmntFinSF50', 'BsmntFinSF51', 'BsmntFinSF52', 'BsmntFinSF53', 'BsmntFinSF54', 'BsmntFinSF55', 'BsmntFinSF56', 'BsmntFinSF57', 'BsmntFinSF58', 'BsmntFinSF59', 'BsmntFinSF60', 'BsmntFinSF61', 'BsmntFinSF62', 'BsmntFinSF63', 'BsmntFinSF64', 'BsmntFinSF65', 'BsmntFinSF66', 'BsmntFinSF67', 'BsmntFinSF68', 'BsmntFinSF69', 'BsmntFinSF70', 'BsmntFinSF71', 'BsmntFinSF72', 'BsmntFinSF73', 'BsmntFinSF74', 'BsmntFinSF75', 'BsmntFinSF76', 'BsmntFinSF77', 'BsmntFinSF78', 'BsmntFinSF79', 'BsmntFinSF80', 'BsmntFinSF81', 'BsmntFinSF82', 'BsmntFinSF83', 'BsmntFinSF84', 'BsmntFinSF85', 'BsmntFinSF86', 'BsmntFinSF87', 'BsmntFinSF88', 'BsmntFinSF89', 'BsmntFinSF90', 'BsmntFinSF91', 'BsmntFinSF92', 'BsmntFinSF93', 'BsmntFinSF94', 'BsmntFinSF95', 'BsmntFinSF96', 'BsmntFinSF97', 'BsmntFinSF98', 'BsmntFinSF99', 'BsmntFinSF100', 'BsmntFinSF101', 'BsmntFinSF102', 'BsmntFinSF103', 'BsmntFinSF104', 'BsmntFinSF105', 'BsmntFinSF106', 'BsmntFinSF107', 'BsmntFinSF108', 'BsmntFinSF109', 'BsmntFinSF110', 'BsmntFinSF111', 'BsmntFinSF112', 'BsmntFinSF113', 'BsmntFinSF114', 'BsmntFinSF115', 'BsmntFinSF116', 'BsmntFinSF117', 'BsmntFinSF118', 'BsmntFinSF119', 'BsmntFinSF120', 'BsmntFinSF121', 'BsmntFinSF122', 'BsmntFinSF123', 'BsmntFinSF124', 'BsmntFinSF125', 'BsmntFinSF126', 'BsmntFinSF127', 'BsmntFinSF128', 'BsmntFinSF129', 'BsmntFinSF130', 'BsmntFinSF131', 'BsmntFinSF132', 'BsmntFinSF133', 'BsmntFinSF134', 'BsmntFinSF135', 'BsmntFinSF136', 'BsmntFinSF137', 'BsmntFinSF138', 'BsmntFinSF139', 'BsmntFinSF140', 'BsmntFinSF141', 'BsmntFinSF142', 'BsmntFinSF143', 'BsmntFinSF144', 'BsmntFinSF145', 'BsmntFinSF146', 'BsmntFinSF147', 'BsmntFinSF148', 'BsmntFinSF149', 'BsmntFinSF150', 'BsmntFinSF151', 'BsmntFinSF152', 'BsmntFinSF153', 'BsmntFinSF154', 'BsmntFinSF155', 'BsmntFinSF156', 'BsmntFinSF157', 'BsmntFinSF158', 'BsmntFinSF159', 'BsmntFinSF160', 'BsmntFinSF161', 'BsmntFinSF162', 'BsmntFinSF163', 'BsmntFinSF164', 'BsmntFinSF165', 'BsmntFinSF166', 'BsmntFinSF167', 'BsmntFinSF168', 'BsmntFinSF169', 'BsmntFinSF170', 'BsmntFinSF171', 'BsmntFinSF172', 'BsmntFinSF173', 'BsmntFinSF174', 'BsmntFinSF175', 'BsmntFinSF176', 'BsmntFinSF177', 'BsmntFinSF178', 'BsmntFinSF179', 'BsmntFinSF180', 'BsmntFinSF181', 'BsmntFinSF182', 'BsmntFinSF183', 'BsmntFinSF184', 'BsmntFinSF185', 'BsmntFinSF186', 'BsmntFinSF187', 'BsmntFinSF188', 'BsmntFinSF189', 'BsmntFinSF190', 'BsmntFinSF191', 'BsmntFinSF192', 'BsmntFinSF193', 'BsmntFinSF194', 'BsmntFinSF195', 'BsmntFinSF196', 'BsmntFinSF197', 'BsmntFinSF198', 'BsmntFinSF199', 'BsmntFinSF200', 'BsmntFinSF201', 'BsmntFinSF202', 'BsmntFinSF203', 'BsmntFinSF204', 'BsmntFinSF205', 'BsmntFinSF206', 'BsmntFinSF207', 'BsmntFinSF208', 'BsmntFinSF209', 'BsmntFinSF210', 'BsmntFinSF211', 'BsmntFinSF212', 'BsmntFinSF213', 'BsmntFinSF214', 'BsmntFinSF215', 'BsmntFinSF216', 'BsmntFinSF217', 'BsmntFinSF218', 'BsmntFinSF219', 'BsmntFinSF220', 'BsmntFinSF221', 'BsmntFinSF222', 'BsmntFinSF223', 'BsmntFinSF224', 'BsmntFinSF225', 'BsmntFinSF226', 'BsmntFinSF227', 'BsmntFinSF228', 'BsmntFinSF229', 'BsmntFinSF230', 'BsmntFinSF231', 'BsmntFinSF232', 'BsmntFinSF233', 'BsmntFinSF234', 'BsmntFinSF235', 'BsmntFinSF236', 'BsmntFinSF237', 'BsmntFinSF238', 'BsmntFinSF239', 'BsmntFinSF240', 'BsmntFinSF241', 'BsmntFinSF242', 'BsmntFinSF243', 'BsmntFinSF244', 'BsmntFinSF245', 'BsmntFinSF246', 'BsmntFinSF247', 'BsmntFinSF248', 'BsmntFinSF249', 'BsmntFinSF250', 'BsmntFinSF251', 'BsmntFinSF252', 'BsmntFinSF253', 'BsmntFinSF254', 'BsmntFinSF255', 'BsmntFinSF256', 'BsmntFinSF257', 'BsmntFinSF258', 'BsmntFinSF259', 'BsmntFinSF260', 'BsmntFinSF261', 'BsmntFinSF262', 'BsmntFinSF263', 'BsmntFinSF264', 'BsmntFinSF265', 'BsmntFinSF266', 'BsmntFinSF267', 'BsmntFinSF268', 'BsmntFinSF269', 'BsmntFinSF270', 'BsmntFinSF271', 'BsmntFinSF272', 'BsmntFinSF273', 'BsmntFinSF274', 'BsmntFinSF275', 'BsmntFinSF276', 'BsmntFinSF277', 'BsmntFinSF278', 'BsmntFinSF279', 'BsmntFinSF280', 'BsmntFinSF281', 'BsmntFinSF282', 'BsmntFinSF283', 'BsmntFinSF284', 'BsmntFinSF285', 'BsmntFinSF286', 'BsmntFinSF287', 'BsmntFinSF288', 'BsmntFinSF289', 'BsmntFinSF290', 'BsmntFinSF291', 'BsmntFinSF292', 'BsmntFinSF293', 'BsmntFinSF294', 'BsmntFinSF295', 'BsmntFinSF296', 'BsmntFinSF297', 'BsmntFinSF298', 'BsmntFinSF299', 'BsmntFinSF300', 'BsmntFinSF301', 'BsmntFinSF302', 'BsmntFinSF303', 'BsmntFinSF304', 'BsmntFinSF305', 'BsmntFinSF306', 'BsmntFinSF307', 'BsmntFinSF308', 'BsmntFinSF309', 'BsmntFinSF310', 'BsmntFinSF311', 'BsmntFinSF312', 'BsmntFinSF313', 'BsmntFinSF314', 'BsmntFinSF315', 'BsmntFinSF316', 'BsmntFinSF317', 'BsmntFinSF318', 'BsmntFinSF319', 'BsmntFinSF320', 'BsmntFinSF321', 'BsmntFinSF322', 'BsmntFinSF323', 'BsmntFinSF324', 'BsmntFinSF325', 'BsmntFinSF326', 'BsmntFinSF327', 'BsmntFinSF328', 'BsmntFinSF329', 'BsmntFinSF330', 'BsmntFinSF331', 'BsmntFinSF332', 'BsmntFinSF333', 'BsmntFinSF334', 'BsmntFinSF335', 'BsmntFinSF336', 'BsmntFinSF337', 'BsmntFinSF338', 'BsmntFinSF339', 'BsmntFinSF340', 'BsmntFinSF341', 'BsmntFinSF342', 'BsmntFinSF343', 'BsmntFinSF344', 'BsmntFinSF345', 'BsmntFinSF346', 'BsmntFinSF347', 'BsmntFinSF348', 'BsmntFinSF349', 'BsmntFinSF350', 'BsmntFinSF351', 'BsmntFinSF352', 'BsmntFinSF353', 'BsmntFinSF354', 'BsmntFinSF355', 'BsmntFinSF356', 'BsmntFinSF357', 'BsmntFinSF358', 'BsmntFinSF359', 'BsmntFinSF360', 'BsmntFinSF361', 'BsmntFinSF362', 'BsmntFinSF363', 'BsmntFinSF364', 'BsmntFinSF365', 'BsmntFinSF366', 'BsmntFinSF367', 'BsmntFinSF368', 'BsmntFinSF369', 'BsmntFinSF370', 'BsmntFinSF371', 'BsmntFinSF372', 'BsmntFinSF373', 'BsmntFinSF374', 'BsmntFinSF375', 'BsmntFinSF376', 'BsmntFinSF377', 'BsmntFinSF378', 'BsmntFinSF379', 'BsmntFinSF380', 'BsmntFinSF381', 'BsmntFinSF382', 'BsmntFinSF383', 'BsmntFinSF384', 'BsmntFinSF385', 'BsmntFinSF386', 'BsmntFinSF387', 'BsmntFinSF388', 'BsmntFinSF389', 'BsmntFinSF390', 'BsmntFinSF391', 'BsmntFinSF392', 'BsmntFinSF393', 'BsmntFinSF394', 'BsmntFinSF395', 'BsmntFinSF396', 'BsmntFinSF397', 'BsmntFinSF398', 'BsmntFinSF399', 'BsmntFinSF400', 'BsmntFinSF401', 'BsmntFinSF402', 'BsmntFinSF403', 'BsmntFinSF404', 'BsmntFinSF405', 'BsmntFinSF406', 'BsmntFinSF407', 'BsmntFinSF408', 'BsmntFinSF409', 'BsmntFinSF410', 'BsmntFinSF411', 'BsmntFinSF412', 'BsmntFinSF413', 'BsmntFinSF414', 'BsmntFinSF415', 'BsmntFinSF416', 'BsmntFinSF417', 'BsmntFinSF418', 'BsmntFinSF419', 'BsmntFinSF420', 'BsmntFinSF421', 'BsmntFinSF422', 'BsmntFinSF423', 'BsmntFinSF424', 'BsmntFinSF425', 'BsmntFinSF426', 'BsmntFinSF427', 'BsmntFinSF428', 'BsmntFinSF429', 'BsmntFinSF430', 'BsmntFinSF431', 'BsmntFinSF432', 'BsmntFinSF433', 'BsmntFinSF434', 'BsmntFinSF435', 'BsmntFinSF436', 'BsmntFinSF437', 'BsmntFinSF438', 'BsmntFinSF439', 'BsmntFinSF440', 'BsmntFinSF441', 'BsmntFinSF442', 'BsmntFinSF443', 'BsmntFinSF444', 'BsmntFinSF445', 'BsmntFinSF446', 'BsmntFinSF447', 'BsmntFinSF448', 'BsmntFinSF449', 'BsmntFinSF450', 'BsmntFinSF451', 'BsmntFinSF452', 'BsmntFinSF453', 'BsmntFinSF454', 'BsmntFinSF455', 'BsmntFinSF456', 'BsmntFinSF457', 'BsmntFinSF458', 'BsmntFinSF459', 'BsmntFinSF460', 'BsmntFinSF461', 'BsmntFinSF462', 'BsmntFinSF463', 'BsmntFinSF464', 'BsmntFinSF465', 'BsmntFinSF466', 'BsmntFinSF467', 'BsmntFinSF468', 'BsmntFinSF469', 'BsmntFinSF470', 'BsmntFinSF471', 'BsmntFinSF472', 'BsmntFinSF473', 'BsmntFinSF474', 'BsmntFinSF475', 'BsmntFinSF476', 'BsmntFinSF477', 'BsmntFinSF478', 'BsmntFinSF479', 'BsmntFinSF480', 'BsmntFinSF481', 'BsmntFinSF482', 'BsmntFinSF483', 'BsmntFinSF484', 'BsmntFinSF485', 'BsmntFinSF486', 'BsmntFinSF487', 'BsmntFinSF488', 'BsmntFinSF489', 'BsmntFinSF490', 'BsmntFinSF491', 'BsmntFinSF492', 'BsmntFinSF493', 'BsmntFinSF494', 'BsmntFinSF495', 'BsmntFinSF496', 'BsmntFinSF497', 'BsmntFinSF498', 'BsmntFinSF499', 'BsmntFinSF500', 'BsmntFinSF501', 'BsmntFinSF502', 'BsmntFinSF503', 'BsmntFinSF504', 'BsmntFinSF505', 'BsmntFinSF506', 'BsmntFinSF507', 'BsmntFinSF508', 'BsmntFinSF509', 'BsmntFinSF510', 'BsmntFinSF511', 'BsmntFinSF512', 'BsmntFinSF513', 'BsmntFinSF514', 'BsmntFinSF515', 'BsmntFinSF516', 'BsmntFinSF517', 'BsmntFinSF518', 'BsmntFinSF519', 'BsmntFinSF520', 'BsmntFinSF521', 'BsmntFinSF522', 'BsmntFinSF523', 'BsmntFinSF524', 'BsmntFinSF525', 'BsmntFinSF526', 'BsmntFinSF527', 'BsmntFinSF528', 'BsmntFinSF529', 'BsmntFinSF530', 'BsmntFinSF531', 'BsmntFinSF532', 'BsmntFinSF533', 'BsmntFinSF534', 'BsmntFinSF535', 'BsmntFinSF536', 'BsmntFinSF537', 'BsmntFinSF538', 'BsmntFinSF539', 'BsmntFinSF540', 'BsmntFinSF541', 'BsmntFinSF542', 'BsmntFinSF543', 'BsmntFinSF544', 'BsmntFinSF545', 'BsmntFinSF546', 'BsmntFinSF547', 'BsmntFinSF548', 'BsmntFinSF549', 'BsmntFinSF550', 'BsmntFinSF551', 'BsmntFinSF552', 'BsmntFinSF553', 'BsmntFinSF554', 'BsmntFinSF555', 'BsmntFinSF556', 'BsmntFinSF557', 'BsmntFinSF558', 'BsmntFinSF559', 'BsmntFinSF560', 'BsmntFinSF561', 'BsmntFinSF562', 'BsmntFinSF563', 'BsmntFinSF564', 'BsmntFinSF565', 'BsmntFinSF566', 'BsmntFinSF567', 'BsmntFinSF568', 'BsmntFinSF569', 'BsmntFinSF570', 'BsmntFinSF571', 'BsmntFinSF572', 'BsmntFinSF573', 'BsmntFinSF574', 'BsmntFinSF575', 'BsmntFinSF576', 'BsmntFinSF577', 'BsmntFinSF578', 'BsmntFinSF579', 'BsmntFinSF580', 'BsmntFinSF581', 'BsmntFinSF582', 'BsmntFinSF583', 'BsmntFinSF584', 'BsmntFinSF585', 'BsmntFinSF586', 'BsmntFinSF587', 'BsmntFinSF588', 'BsmntFinSF589', 'BsmntFinSF590', 'BsmntFinSF591', 'BsmntFinSF592', 'BsmntFinSF593', 'BsmntFinSF594', 'BsmntFinSF595', 'BsmntFinSF596', 'BsmntFinSF597', 'BsmntFinSF598', 'BsmntFinSF599', 'BsmntFinSF600', 'BsmntFinSF601', 'BsmntFinSF602', 'BsmntFinSF603', 'BsmntFinSF604', 'BsmntFinSF605', 'BsmntFinSF606', 'BsmntFinSF607', 'BsmntFinSF608', 'BsmntFinSF609', 'BsmntFinSF610', 'BsmntFinSF611', 'BsmntFinSF612', 'BsmntFinSF613', 'BsmntFinSF614', 'BsmntFinSF615', 'BsmntFinSF616', 'BsmntFinSF617', 'BsmntFinSF618', 'BsmntFinSF619', 'BsmntFinSF620', 'BsmntFinSF621', 'BsmntFinSF622', 'BsmntFinSF623', 'BsmntFinSF624', 'BsmntFinSF625', 'BsmntFinSF626', 'BsmntFinSF627', 'BsmntFinSF628', 'BsmntFinSF629', 'BsmntFinSF630', 'BsmntFinSF631', 'BsmntFinSF632', 'BsmntFinSF633', 'BsmntFinSF634', 'BsmntFinSF635', 'BsmntFinSF636', 'BsmntFinSF637', 'BsmntFinSF638', 'BsmntFinSF639', 'BsmntFinSF640', 'BsmntFinSF641', 'BsmntFinSF642', 'BsmntFinSF643', 'BsmntFinSF644', 'BsmntFinSF645', 'BsmntFinSF646', 'BsmntFinSF647', 'BsmntFinSF648', 'BsmntFinSF649', 'BsmntFinSF650', 'BsmntFinSF651', 'BsmntFinSF652', 'BsmntFinSF653', 'BsmntFinSF654', 'BsmntFinSF655', 'BsmntFinSF656', 'BsmntFinSF657', 'BsmntFinSF658', 'BsmntFinSF659', 'BsmntFinSF660', 'BsmntFinSF661', 'BsmntFinSF662', 'BsmntFinSF663', 'BsmntFinSF664', 'BsmntFinSF665', 'BsmntFinSF666', 'BsmntFinSF667', 'BsmntFinSF668', 'BsmntFinSF669', 'BsmntFinSF670', 'BsmntFinSF671', 'BsmntFinSF672', 'BsmntFinSF673', 'BsmntFinSF674', 'BsmntFinSF675', 'BsmntFinSF676', 'BsmntFinSF677', 'BsmntFinSF678', 'BsmntFinSF679', 'BsmntFinSF680', 'BsmntFinSF681', 'BsmntFinSF682', 'BsmntFinSF683', 'BsmntFinSF684', 'BsmntFinSF685', 'BsmntFinSF686', 'BsmntFinSF687', 'BsmntFinSF688', 'BsmntFinSF689', 'BsmntFinSF690', 'BsmntFinSF691', 'BsmntFinSF692', 'BsmntFinSF693', 'BsmntFinSF694', 'BsmntFinSF695', 'BsmntFinSF696', 'BsmntFinSF697', 'BsmntFinSF698', 'BsmntFinSF699', 'BsmntFinSF700', 'BsmntFinSF701', 'BsmntFinSF702', 'BsmntFinSF703', 'BsmntFinSF704', 'BsmntFinSF705', 'BsmntFinSF706', 'BsmntFinSF707', 'BsmntFinSF708', 'BsmntFinSF709', 'BsmntFinSF710', 'BsmntFinSF711', 'BsmntFinSF712', 'BsmntFinSF713', 'BsmntFinSF714', 'BsmntFinSF715', 'BsmntFinSF716', 'BsmntFinSF717', 'BsmntFinSF718', 'BsmntFinSF719', 'BsmntFinSF720', 'BsmntFinSF721', 'BsmntFinSF722', 'BsmntFinSF723', 'BsmntFinSF724', 'BsmntFinSF725', 'BsmntFinSF726', 'BsmntFinSF727', 'BsmntFinSF728', 'BsmntFinSF729', 'BsmntFinSF730', 'BsmntFinSF731', 'BsmntFinSF732', 'BsmntFinSF733', 'BsmntFinSF734', 'BsmntFinSF735', 'BsmntFinSF736', 'BsmntFinSF737', 'BsmntFinSF738', 'BsmntFinSF739', 'BsmntFinSF740', 'BsmntFinSF741', 'BsmntFinSF742', 'BsmntFinSF743', 'BsmntFinSF744', 'BsmntFinSF745', 'BsmntFinSF746', 'BsmntFinSF747', 'BsmntFinSF748', 'BsmntFinSF749', 'BsmntFinSF750', 'BsmntFinSF751', 'Bsmnt
```